ESCUELA POLITÉCNICA NACIONAL

FACULTAD DE CIENCIAS

Patrones de conducción en las rutas en la EPMTPQ

31, OCTUBRE 2025

Índice general

1. Metodología **1**
1.1. Medidas de similitud 1
1.2. k-means 2
1.2.1. Determinación del número óptimo de clusters 4
1.3. Clúster jerárquico 7
1.4. Índices de validación 8
1.4.1. Índice de Calinski y Harabasz 9
1.4.2. Índice de la Silueta 9
1.4.3. índice de Dunn 9
1.4.4. Índice de David Bouldin 9

2. Resultados **11**
2.1. Instancias del experimento 11
2.2. Pruebas realizadas 12
2.2.1. Granularidad de las observaciones 12
2.2.2. Variables observadas 12
2.2.3. Combinaciones experimentales 13
2.3. Procedimiento 13
2.3.1. Método *k-means* 13
2.3.2. Método jerárquico 14
2.4. Resultados 14
2.4.1. Instancia E1 (1xPARADA, V-MAX) 14
2.4.2. Mejores resultados 18

Bibliografía **21**

RESUMEN

Con el objetivo de identificar tendencias y patrones significativos en el comportamiento operativo del sistema de transporte público, tales como horarios de viaje, género del conductor y tipo de unidad vehicular. En el pesente trabajo se aplican distintos métodos de agrupamiento basados en los perfiles de velocidad registrados en los viajes de las dos rutas de la Empresa Pública Metropolitana de Transporte de Pasajeros de Quito (EPMTPQ). Los resultados buscan evidenciar la existencia de patrones sistemáticos que contribuyan a la toma de decisiones más informadas y a la mejora de la gestión del transporte público.

Palabras clave: Empresa Pública Metropolitana de Transporte de Pasajeros de Quito, patrones de conducción, perfiles de velocidad, métodos de agrupamiento.

Capítulo 1

Metodología

1.1. Medidas de similitud

Las **medidas de similitud** (o distancia) son métricas matemáticas que cuantifican qué tan parecidos o diferentes son dos individuos u objetos. En el contexto del análisis de agrupamiento, estas medidas son fundamentales para determinar si los individuos deben agruparse juntos o no. Estas medidas se pueden clasificar en tres grupos según su naturaleza y aplicabilidad [2]:

- **Grupo 1: Métricas de distancia**. Estas medidas cuantifican la separación espacial entre dos puntos en un espacio multidimensional. Solo funcionan para variables cuantitativas (excepto la distancia binaria, que es para variables binarias):
  - **Distancia Euclideana**: $d(x, y) = \sqrt{\sum_{i=1}^{p}(x_i - y_i)^2}$ — La distancia de línea recta en el espacio.
  - **Distancia Manhattan**: $d(x, y) = \sum_{i=1}^{p} |x_i - y_i|$ — La suma de diferencias absolutas.
  - **Distancia Máxima**: $d(x, y) = \text{máx}_{i=1}^{p} |x_i - y_i|$ — La mayor diferencia entre cualquier dimensión.
  - **Distancia Minkowski**: $d(x, y) = \left(\sum_{i=1}^{p} |x_i - y_i|^r\right)^{1/r}$ — Generalización de otras distancias (donde $r \geq 1$).
  - **Distancia Mahalanobis**: $d(x, y) = \sqrt{(x - y)^T \Sigma^{-1} (x - y)}$ — Considera la correlación entre variables (donde Σ es la matriz de covarianza).

- **Distancia Canberra**: $d(x,y) = \sum_{i=1}^{p} \frac{|x_i - y_i|}{|x_i| + |y_i|}$ — Normaliza las diferencias por las magnitudes de los valores.
- **Distancia Binaria**: $d(x,y) = \frac{c_{TF} + c_{FT}}{c_{TT} + c_{TF} + c_{FT} + c_{FF}}$ — Para variables binarias (0/1 o Falso/Verdadero).

- **Grupo 2: Métricas de correlación**. Estas medidas se basan en el grado de asociación lineal entre dos variables. Son apropiadas para variables cuantitativas:
  - **Correlación de Pearson**: $r(x,y) = \frac{\sum_{i=1}^{p}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{p}(x_i - \bar{x})^2}\sqrt{\sum_{i=1}^{p}(y_i - \bar{y})^2}}$ — Mide la relación lineal entre dos variables (valores entre -1 y 1).

- **Grupo 3: Coeficientes de asociación**. Estas medidas son adecuadas para variables cualitativas (categóricas) y se calculan a partir de tablas de contingencia binarias:
  - **Coeficiente de asociación simple**: $s(x,y) = \frac{c_{TT} + c_{FF}}{c_{TT} + c_{TF} + c_{FT} + c_{FF}}$ — Razón de coincidencias totales.
  - **Coeficiente de Jaccard**: $J(x,y) = \frac{c_{TT}}{c_{TT} + c_{TF} + c_{FT}}$ — Solo considera las coincidencias positivas.
  - **Coeficiente de Rogers y Tanimoto**: $RT(x,y) = \frac{c_{TT} + c_{FF}}{c_{TT} + 2(c_{TF} + c_{FT}) + c_{FF}}$ — Penaliza los desajustes.
  - **Coeficiente de Sørensen o Dice**: $S(x,y) = \frac{2c_{TT}}{2c_{TT} + c_{TF} + c_{FT}}$ — Énfasis en coincidencias positivas.
  - **Coeficiente de Sokal y Sneath**: $SS(x,y) = \frac{2(c_{TT} + c_{FF})}{2(c_{TT} + c_{FF}) + c_{TF} + c_{FT}}$ — Considera ambas coincidencias.
  - **Coeficiente de Hamann**: $H(x,y) = \frac{(c_{TT} + c_{FF}) - (c_{TF} + c_{FT})}{c_{TT} + c_{TF} + c_{FT} + c_{FF}}$ — Diferencia entre coincidencias y desajustes.

donde x e y representan dos individuos, p es el número de variables, c_{TT}, c_{TF}, c_{FT} y c_{FF} son los conteos de coincidencias y desajustes en variables binarias, y $\bar{x}$, $\bar{y}$ son los promedios de cada variable.

1.2. k-means

El algoritmo de k-means es un método de partición no supervisada, esta requiere de cuatro etapas[1]:

- Seleccionar k puntos como centros de los grupos iniciales, esto puede hacerse:
  - Asignando aleatoriamente los objetos a los grupos y tomando los centros de los grupos así formados;
  - Tomando como centros los k puntos más alejados entre sí;
  - Construyendo los grupos con información a priori, o bien seleccionando los centros a priori.
- Calcular la distancia de cada elemento al centro de los k grupos, y asignar cada elemento al grupo más próximo. La asignación se realiza secuencialmente y al introducir un nuevo elemento en un grupo se recalculan las coordenadas de la nueva media de grupo.
- Definir un criterio de optimalidad y comprobar si reasignando uno a uno cada elemento de un grupo a otro mejora el criterio.
- Si no es posible mejorar el criterio de optimalidad, termina el proceso.

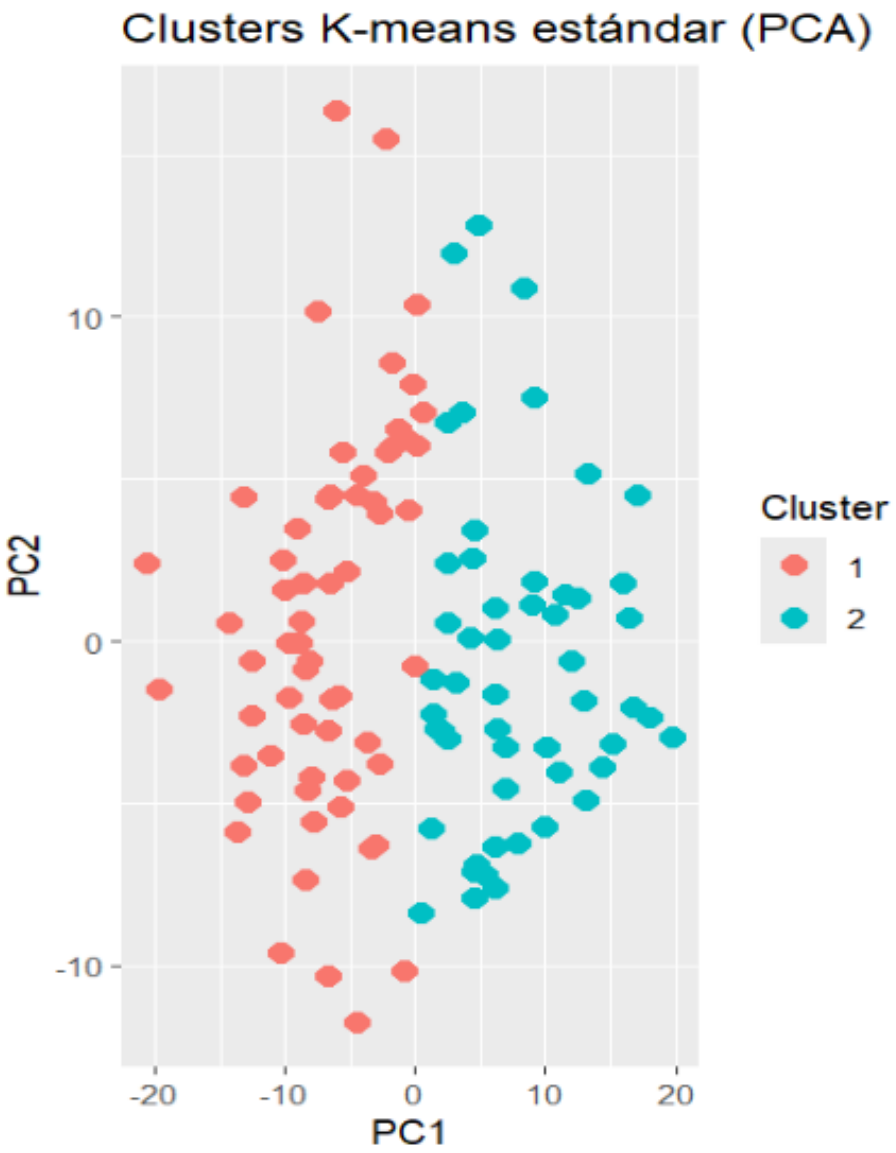

Figura 1.1: Resultado de aplicar el algoritmo de agrupamiento k-means a un conjunto de datos utilizando la distancia Euclideana como medida de similitud. Los datos se visualizan en un espacio bidimensional obtenido mediante Análisis de Componentes Principales (PCA)

Para la implementación del algoritmo, es necesario saber qué cantidad de centroides es la óptima, para ello existen varios métodos [1]:

1.2.1. Determinación del número óptimo de clusters

Método del codo

A medida que aumentamos el número de clusters en el k-means, el valor de WCSS (Within-Cluster Sum of Squares) decrece. Esto se debe a que

existirá menor variabilidad dentro de cada grupo. Sin embargo, después de cierto número de clusters, las reducciones adicionales son marginales. El WCSS se define como:

$$\text{WCSS} = \sum_{k=1}^{G} \sum_{i \in C_k} \|x_i - \mu_k\|^2$$

donde G es el número total de clusters, C_k representa el conjunto de individuos pertenecientes al cluster k, x_i es el vector de características del individuo i, y μ_k es el centroide del cluster k. Esta métrica cuantifica la cohesión dentro de los clusters: valores menores indican clusters más compactos.

El número óptimo de clusters se identifica como el **codo** de la curva, es decir, el punto donde la disminución del WCSS comienza a ser marginal. Gráficamente, esto corresponde al **codo** en la representación del WCSS contra el número de clusters.

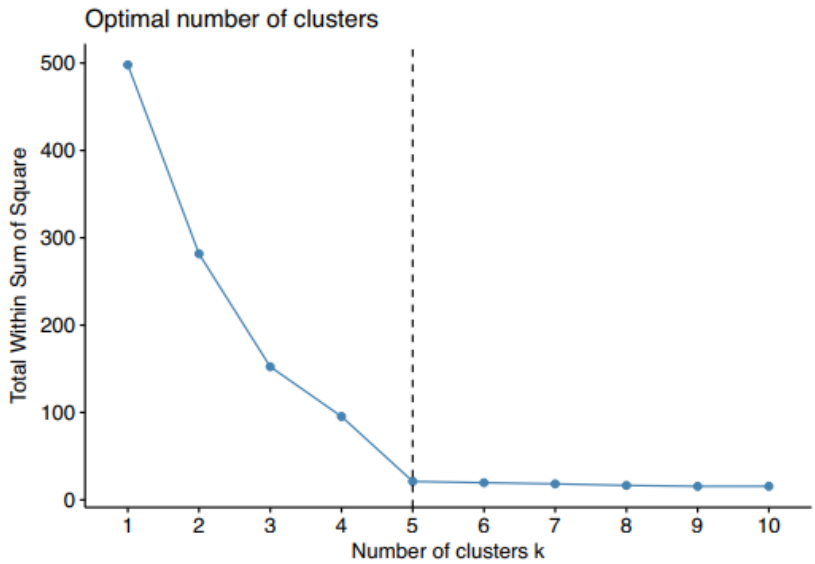

Figura 1.2: La gráfica muestra la suma total de cuadrados dentro de los clusters (WCSS) en función del número de clusters k. El punto de inflexión (señalado por la línea punteada) indica el número óptimo de clusters, donde la disminución marginal del WCSS se vuelve insignificante.

Método de la silueta

Realiza un análisis elemento a elemento. La idea detrás de esta métrica es dada una partición, comparar lo cerca que está cada elemento de su *cluster* con los elementos del *cluster* más cercano.

Definición 1.2.1. Sea $X \subset \mathbb{R}^p$ una muestra de n datos, d una distancia y se $\{C_i\}_{i=1}^k$ una partición de la misma. Para un elemento $x \in C_r \subset X$, se definen la desimilaridad intra cluster e inter cluster como:

$$a(x) = \frac{1}{|C_r|} \sum_{y \in C_r} d(x, y)$$
$$b(x) = \operatorname*{máx}_{r \neq i = 1, \ldots, k} \frac{1}{|C_i|} \sum_{y \in C_i} d(y, x)$$

Se necesita de una partición previa, y por tanto, el valor del índice dependerá del algoritmo utilizado para obtenerla. El valor $a(i)$ da la distancia promedio de un elemento al resto de su clase, mientras que $b(i)$ indica la distancia primerio al segundo mejor *cluster* para el elemento, es decir, el que sin ser su *cluster* está más cerca del elemento. Así obtenemos la siguiente métrica

Definición 1.2.2. Sea $X \subset \mathbb{R}^p$ una muestra de n datos, d una distancia y se $\{C_i\}_{i=1}^k$ una partición de la misma. Para un elemento $x \in C_r \subset X$, se define el índice de silueta del elemento x como:

$$s(x) = \frac{b(x) - a(x)}{\operatorname{máx}\{a(x), b(x)\}}$$

El rango del índice de silueta es $-1 < s(x) < 1$. En el caso de un elemento x en un *cluster* compacto y bien diferenciado del resto lo que ocurre es que $a(x)$ es mucho menor que $b(x)$ entonces el índice se aproximará a 1. Mientras que en el caso contrario el indice se aproxima a -1.

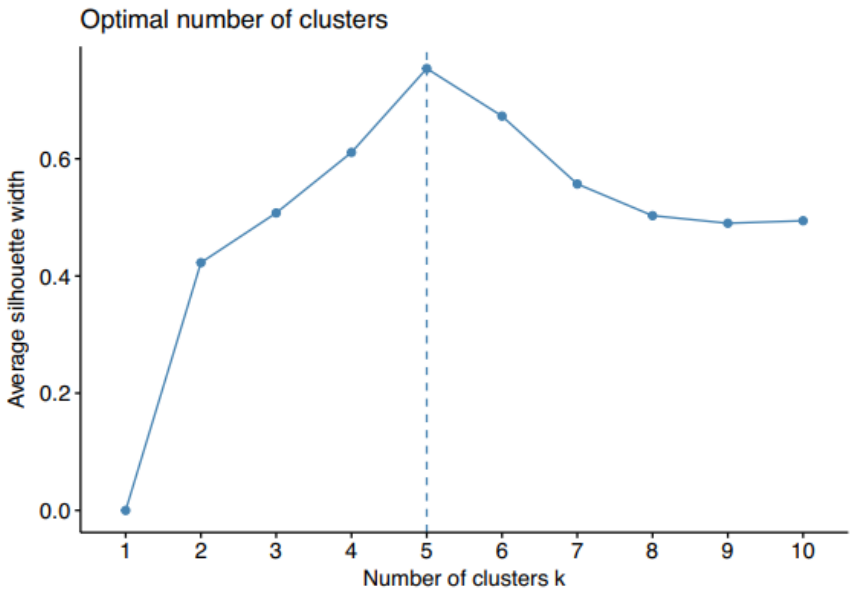

Figura 1.3: Análisis de silueta para evaluar la calidad del agrupamiento. La línea punteada marca el número óptimo de clusters, correspondiente al valor máximo del coeficiente de silueta promedio.

1.3. Clúster jerárquico

Los algoritmos de clústering jerárquicos construyen subconjuntos de clústeres organizados jerárquicamente como un árbol, siguiendo un método o criterio de aglomeración [2]. Para los métodos de clústering aglomerativos es necesario seleccionar una medida de similitud, un criterio para determinar el número óptimo de clústeres y un método de aglomeración, luego:

1. Calcular una matriz de proximidad.
2. Iniciar con cada individuo siendo un clúster.
3. Unir los dos clústeres más cercanos.
4. Actualizar la matriz de proximidad.
5. Repetir 3 y 4 hasta que solo quede un clúster.

Los métodos de aglomeración corresponden a las formas como el algoritmo jerárquico de agrupamiento va incluyendo a cada individuo en un grupo de manera iterativa, tenemos:

- enlace único (distancia más pequeña)

- enlace completo (distancia máxima)
- enlace promedio (distancia promedio)
- enlace mediano (mediana)
- centroide (define la distancia entre dos clústers como el cuadrado de la distancia euclideana entre los centros de gravedad de los dos grupos)
- Ward.D (minimizar la varianza total dentro del grupo)
- Ward.D2 (modificación de Ward, que implica elevar al cuadrado la diferencia encontrada antes de la actualización del grupo)
- McQuitty (media ponderada de las diferencias al interior de los conglomerados)

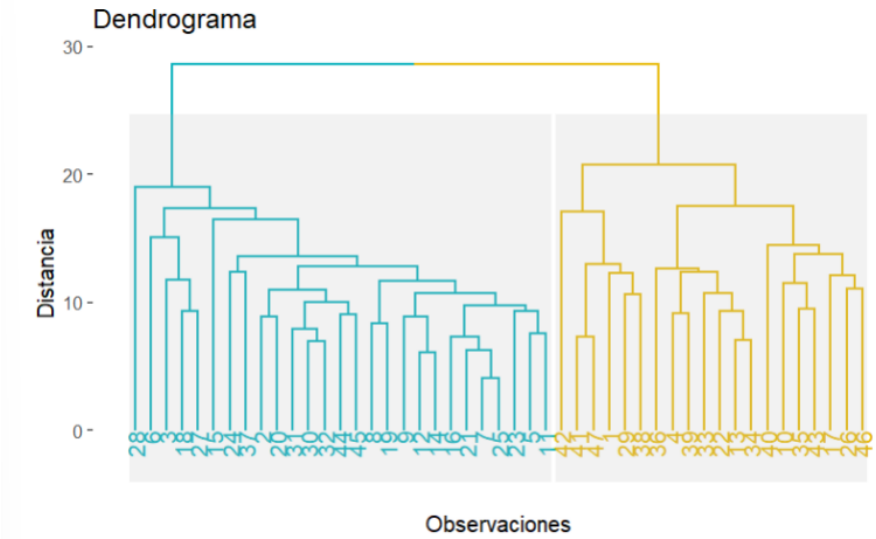

Figura 1.4: Dendrograma del agrupamiento jerárquico aglomerativo. Cada rama representa la distancia a la cual se unen dos individuos o clusters. La altura de las ramas indica la similitud entre los grupos: ramas más altas indican clusters menos similares. Los colores distinguen los clusters principales identificados en el análisis.

1.4. Índices de validación

En la literatura se han desarrollado una gran variedad de índices de validación que permitan comparar diferentes aproximaciones :

1.4.1. Índice de Calinski y Harabasz

.

El índice de Calinski y Harabasz está definido como:

$$CH(q) = \frac{tr(B_q)/(q-1)}{tr(W_q)/(n-q)}$$

donde tr representa la traza de una matriz. El valor de q que maximiza la función $CH(q)$ sería el número de clústeres seleccionado con este método.

1.4.2. Índice de la Silueta

En la determinación del número óptimo de clusters ya se expuso este método. El valor máximo del índice es usado para determinar el número óptimo de clústeres.

1.4.3. índice de Dunn

El índice de Dunn define un ratio entre la distancia mínima entre clústeres y la distancia máxima intraclúster. Es decir,

$$Dunn = \frac{\text{mín}_{1 \leq i < j \leq q}\, d(C_i, C_j)}{\text{máx}_{1 \leq k \leq q}\, diam(C_k)}$$

donde $d(C_i, C_j)$ es la función de la diferencia entre dos clústeres C_i y C_j, definida como
$d(C_i, C_j) = \text{mín}_{x \in C_i, y \in C_j}\, d(x, y)$ y $diam(C)$ es el diámetro del clúster, que puede ser considerado una medida de dispersión del clúster. Se puede definir de la siguiente manera:

$$diam(C) = \underset{x,y \in C}{\text{máx}}\, d(x, y)$$

Si tenemos clústeres compactos y bien separados, se espera que el diámetro de los clústeres sea pequeño y la distancia entre los clústeres sea grande. Por eso, el índice debe ser maximizado.

1.4.4. Índice de David Bouldin

El índice de Davies & Bouldin es una función de la suma de ratios intraclúster dispersos a separación interclúster. Este índice se define como:

$$DB(q) = \frac{1}{q} \sum_{k=1}^{q} \operatorname*{máx}_{k \neq l} \left(\frac{\delta_k + \delta_l}{D_{kl}} \right)$$

donde $k, l = 1, \ldots, q$ es el número de clústeres.
$D_{kl} = \sqrt[v]{\sum_{j=1}^{d} |c_{kj} - c_{lj}|^v}$ es la distancia de Minkowski entre los centroides de los clústeres C_k y C_l. δ_k es una medida de dispersión de un clúster C_k con respecto al centroide de ese clúster empleando la distancia Minkowski.
Según Milligan & Cooper y Davies & Bouldin, el valor de q que minimiza DB(q) corresponde al número de clústeres óptimo.

Capítulo 2

Resultados

2.1. Instancias del experimento

Los datos utilizados en este estudio se obtuvieron de los sistemas internos de la Empresa Pública Metropolitana de Transporte de Pasajeros de Quito (EPMTPQ), específicamente de las plataformas *Traccar* y *Odoo*. La información fue descargada por días y corresponde a tres líneas operativas, de la Ecovía: la ruta E1 (Universidades) y la ruta C1 del Trolebús, tanto en sentido sur–norte (C1SN) como norte–sur (C1NS).
Para la ruta E1, se recopilaron 113 viajes: 16 correspondientes al 5 de agosto de 2025 y 97 al 1 de agosto de 2025. En cuanto a la ruta C1, se registraron 137 viajes el 1 de agosto de 2025, distribuidas en 70 para el sentido C1NS y 67 para el sentido C1SN.
El primer viaje del día en la ruta C1NS inició a las 05:01 y el último concluyó a las 22:21. Para el sentido C1SN, los horarios correspondientes fueron 04:49 y 22:28. Finalmente, en la ruta E1, el primer viaje comenzó a las 05:03 y el último terminó a las 20:52.

Cuadro 2.1: Instancias del experimento

Rutas	**N.º de viajes**	**Días de recopilación**	**Hora inicio**	**Hora fin**
E1 (Universidades)	113	1 y 5 ago. 2025	05:03	20:52
C1NS (Trolebús N→S)	70	1 ago. 2025	05:01	22:21
C1SN (Trolebús S→N)	67	1 ago. 2025	04:49	22:28
Total	**250**			

Las instancias corresponden a los datos utilizados en el experimento, obtenidos de los sistemas *Traccar* y *Odoo* de la Empresa Pública Metropolitana de Transporte de Pasajeros de Quito (EPMTPQ).

2.2. Pruebas realizadas

Para cada ruta se llevaron a cabo seis experimentos, clasificados según la granularidad de las observaciones y las variables analizadas.

2.2.1. Granularidad de las observaciones

La granularidad define el nivel de detalle con el que se agrupan las observaciones a lo largo del recorrido de las rutas. Se consideraron dos niveles:

- **1xPARADA:** Las observaciones se promediaron para obtener un único valor entre cada par de paradas consecutivas.
- **3xPARADA:** Las observaciones entre cada par de paradas se dividieron en tres grupos equidistantes. Para cada grupo se calculó el promedio, obteniendo tres valores entre cada par de paradas.

2.2.2. Variables observadas

Se analizaron tres variables principales derivadas de las mediciones de velocidad:

- **V-PROM:** Velocidad promedio.
- **V-MAX:** Velocidad máxima.
- **V-DEST:** Desviación estándar de la velocidad.

2.2.3. Combinaciones experimentales

A partir de las combinaciones entre los niveles de granularidad y las variables observadas, se definieron los siguientes seis experimentos por ruta:

- 1xPARADA,V-PROM
- 1xPARADA,V-MAX
- 1xPARADA,(V-PROM, V-MAX, V-DEST)
- 3xPARADA,V-PROM
- 3xPARADA,V-MAX
- 3xPARADA,(V-PROM, V-MAX, V-DEST)

En total, considerando las tres rutas (*E1*, *C1NS* y *C1SN*), se realizaron 18 experimentos.

2.3. Procedimiento

Los experimentos se realizaron en una computadora con sistema operativo *Windows 11*, equipada con 16 GB de memoria RAM, 932 GB de almacenamiento, diez núcleos físicos y un procesador *12th Gen Intel(R) Core(TM) i7-1255U*.
El código se implementó en el lenguaje de programación **R**. Para cada una de las pruebas definidas, se aplicaron los métodos de agrupamiento *k-means* y jerárquico, considerando diversas configuraciones de distancias, métodos de enlace e índices de validación.

2.3.1. Método *k-means*

En el método *k-means* se emplearon las distancias **euclídea** y **máxima**. Los centroides iniciales se seleccionaron de manera aleatoria, repitiendo el proceso 25 veces y eligiendo la configuración con el menor valor de la suma de cuadrados intra-cluster (*Within-Cluster Sum of Squares*, WCSS), que constituye el criterio de optimalidad.
Para determinar el número óptimo de clústeres, se evaluaron las distancias **euclídea**, **manhattan**, **máxima** y **minkowski**. Los índices de validación empleados fueron: **Silhouette**, **Calinski–Harabasz** y **Dunn**.

2.3.2. Método jerárquico

También se implementó el método jerárquico de agrupamiento, considerando los siguientes criterios de enlace: **single**, **complete**, **average**, **McQuitty**, **median**, **centroid**, **Ward.D** y **Ward.D2**. Las distancias utilizadas fueron: **Euclídea**, **Máxima**, **Manhattan**, **Canberra** y **Minkowski**.
Para cada combinación de método de enlace, métrica de distancia y cantidad de clústeres ($k = 2, 3, 4$), se obtuvieron un total de **120 configuraciones experimentales**. Los índices de validación empleados fueron: **Dunn**, **Calinski–Harabasz**, **Silhouette** y **Davies–Bouldin**.
Finalmente, los resultados obtenidos en ambos métodos de agrupamiento permitieron comparar el desempeño y la coherencia de las estructuras de clústeres bajo diferentes configuraciones de parámetros y métricas de similitud.

2.4. Resultados

2.4.1. Instancia E1 (1xPARADA, V-MAX)

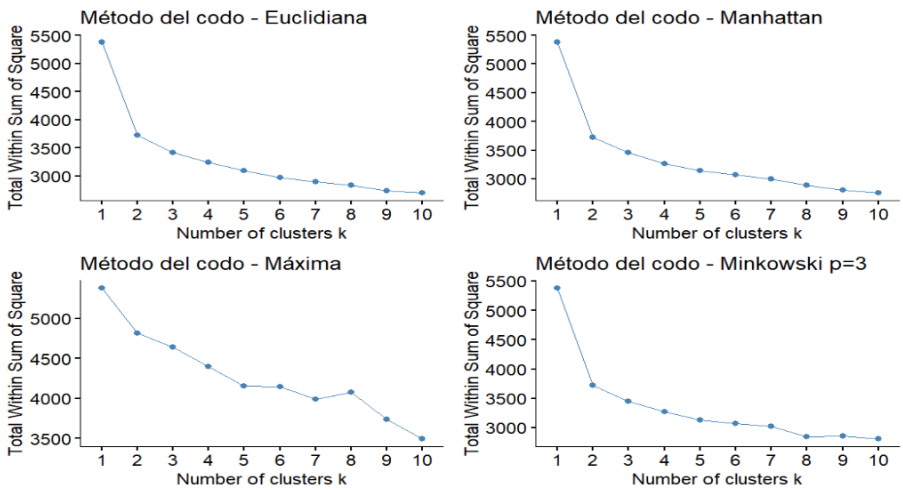

Figura 2.1: Método del codo con diferentes medidas.

El método del codo muestra una clara inflexión en k=2 para todas las métricas de distancia evaluadas, excepto la máxima. Después de este punto, la disminución en la suma total de cuadrados dentro de los clusters se vuelve marginal, lo que indica que k=2 es el número óptimo de clusters para este experimento.

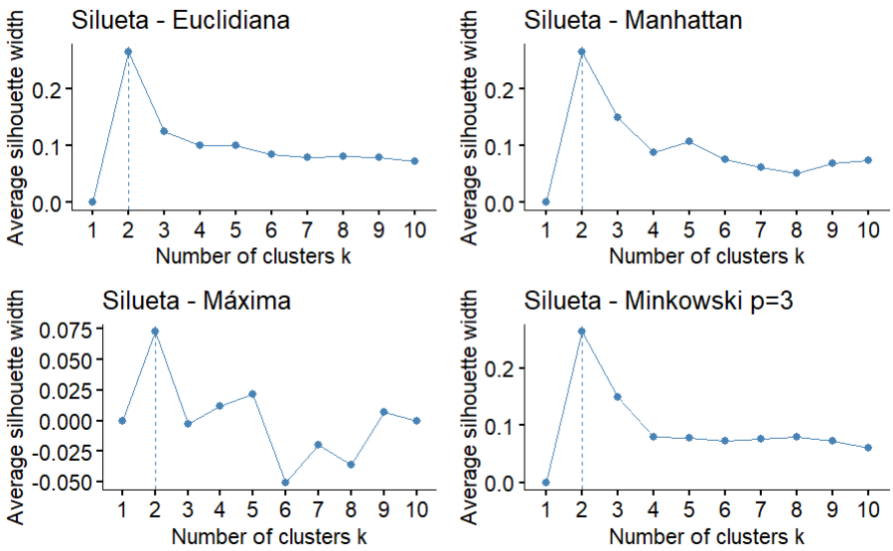

Figura 2.2: Método de la Silueta con diferentes medidas.

El coeficiente de silueta alcanza su valor máximo en $k = 2$ para todas las métricas evaluadas, indicando una excelente separación y cohesión de los clusters con esta configuración. Este resultado valida consistentemente que $k = 2$ es la configuración óptima, confirmando lo observado en el método del codo. La convergencia de todas las métricas hacia el mismo valor de k refuerza la robustez de esta elección.

Cuadro 2.2: Resultados obtenidos para el método *k-means* en la instancia E1 (1xPARADA, V-MAX)

Distancia	**Silueta**	**Dunn**	**Calinski–Harabasz**
Euclídea	0.265	0.360	49.44
Máxima	0.084	0.213	13.02

El K-means estándar con distancia euclidiana supera consistentemente al K-means con distancia máxima en todos los índices evaluados. La Silueta del método estándar (0.265) es más del triple que la del método con distancia máxima (0.084), indicando una asignación significativamente más coherente de las observaciones a sus clusters. Similarmente, los índices de Calinski (49.44 vs. 13.03) y Dunn (0.36 vs. 0.21) confirman que la distancia euclidiana produce clusters más compactos y mejor separados para este conjunto de datos de velocidades máximas.

Las tablas a continuación presentan los resultados del clustering jerárquico ordenados de mayor a menor según cada índice de validación específico:

Cuadro 2.3: Índice de Dunn para evaluación de la calidad de clustering con el método jerárquico

Rank	Link	Dist	k	Dunn	Calinski	Silueta	Davies.B
1	complete	canberra	4	0.6354	20.9371	0.1726	2.1312
2	average	canberra	2	0.6315	47.5995	0.2700	1.4492
3	average	canberra	3	0.6315	25.0417	0.2017	1.3220
4	average	canberra	4	0.6315	17.7083	0.1635	1.3179
5	ward.D2	canberra	2	0.6265	45.6050	0.2653	1.4541

La distancia Canberra domina el ranking de Dunn con valores superiores a 0.62, indicando buena separación entre clusters. Los métodos average y complete con $k = 2$ presentan el mejor balance, aunque sus valores de Silueta son relativamente bajos ($\approx 0{,}27$), sugiriendo que los clusters están bien separados pero con dispersión interna moderada. El índice de Davies-Bouldin alto ($> 1{,}4$) confirma esta dispersión interna.

Cuadro 2.4: Índice de Calinski-Harabasz para evaluación de la calidad de clustering con el método jerárquico

Rank	Link	Dist	k	Dunn	Calinski	Silueta	Davies.B
1	complete	manhattan	2	0.3317	67.8474	0.3134	1.4819
2	ward.D	manhattan	2	0.2481	59.6431	0.2795	1.5860
3	ward.D2	manhattan	2	0.3054	57.4609	0.3042	1.4429
4	mcquitty	manhattan	2	0.2838	50.3983	0.2985	1.4217
5	ward.D2	euclidean	2	0.3599	48.6327	0.2624	1.4569

Los valores de Calinski-Harabasz son consistentemente elevados (47-68) con la distancia Manhattan y métodos Ward/complete para $k = 2$. Los valores de Silueta moderados ($\approx 0{,}30$) y Dunn bajos ($< 0{,}36$) sugieren que estos valores altos de Calinski no reflejan una verdadera calidad superior del clustering.

Cuadro 2.5: Índice de Silueta para evaluación de la calidad de clustering con el método jerárquico

Rank	Link	Dist	k	Dunn	Calinski	Silueta	Davies.B
1	single	maximum	2	0.5617	4.8928	0.4077	0.7313
2	centroid	maximum	2	0.5617	4.8928	0.4077	0.7313
3	complete	maximum	2	0.4638	6.1333	0.3455	1.6006
4	average	maximum	2	0.4638	6.1333	0.3455	1.6006
5	mcquitty	maximum	2	0.4638	6.1333	0.3455	1.6006

La distancia maximum con métodos single y centroid produce los mejores valores de Silueta (0.408), representando el clustering más balanceado del análisis. Estos resultados también presentan el Davies-Bouldin más bajo (0.73), confirmando clusters compactos y bien separados. Todos los mejores resultados corresponden a $k = 2$, sugiriendo que la velocidad máxima en este nivel de granularidad identifica naturalmente dos patrones de conducción diferenciados.

Cuadro 2.6: Índice de Davies-Bouldin para evaluación de la calidad de clustering con el método jerárquico

Rank	Link	Dist	k	Dunn	Calinski	Silueta	Davies.B
1	centroid	euclidean	2	0.3986	2.6985	0.2258	0.5899
2	centroid	manhattan	2	0.3703	3.1103	0.2618	0.5899
3	centroid	minkowski	2	0.3986	2.6985	0.2258	0.5899
4	centroid	euclidean	3	0.3686	2.6928	0.0630	0.5940
5	centroid	manhattan	3	0.2918	3.0606	0.0700	0.5940

El método centroid con distancias euclidean, manhattan y minkowski logra los valores más bajos de Davies-Bouldin ($\approx 0{,}59$) para $k = 2$, indicando clusters relativamente compactos. Sin embargo, los valores de Silueta son notablemente bajos ($\approx 0{,}23$), revelando una contradicción: aunque los clusters son compactos según Davies-Bouldin, la asignación individual de puntos es débil. Esta discrepancia, junto con valores moderados de Dunn ($\approx 0{,}37$), sugiere que estas configuraciones producen agrupaciones geométricamente compactas pero sin clara diferenciación entre patrones de conducción.

Al comparar todos los métodos evaluados utilizando el criterio de prio-

rización (Silueta >Davies-Bouldin >Dunn >Calinski), el **clustering jerárquico con linkage single/centroid, distancia maximum y** $k = 2$ emerge como la mejor configuración global, con Silueta de 0.408, Davies-Bouldin de 0.73 y Dunn de 0.56. Este resultado supera claramente al k-means.
La superioridad del método jerárquico con distancia maximum se explica por su capacidad para identificar clusters basándose en las diferencias más extremas entre observaciones, lo cual es particularmente relevante para detectar patrones de conducción donde las velocidades máximas representan comportamientos críticos. Aunque los métodos jerárquicos con distancia Canberra obtuvieron mejores valores de Dunn (0.63), sus valores de Silueta extremadamente bajos (0.17-0.27) y Davies-Bouldin altos (>1.3) los descalifican como opciones viables. En conclusión, para el análisis de patrones de conducción con velocidad máxima en granularidad 1xPARADA, se recomienda el **clustering jerárquico (single/centroid + maximum +** $k = 2$**)** como la metodología óptima.
Realizando un análisis similar con los demás experimentos, obtenemos:

2.4.2. Mejores resultados

Cuadro 2.7: Resumen de resultados obtenidos en los experimentos por instancia

Instancia	Experimento	Método	Distancia	N.º Clústeres	Métrica	Dunn	Calinski	Silueta	Davies–Bouldin
E1	1xPARADA, V-MAX	Jerárquica	Máxima	2	single/centroid	0.56	4.89	0.41	0.73
E1	1xPARADA, V-PROM	Jeráquica	Manhattan	2	average/mcquitty/median/centroid	0.55	2.40	0.22	0.64
E1	1xPARADA, V-PROM, V-MAX, V-DEST	Jeráquica	Máxima	2	single/centroid	0.62	3.18	0.29	0.89
E1	3xPARADA, V-PROM	Jerárquica	Máxima	2	single/average/mcquitty/centroid	0.53	2.31	0.21	0.88
E1	3xPARADA, V-MAX	Jerárquica	Máxima	2	single/centroid	0.49	2.52	0.23	0.99
E1	3xPARADA, V-PROM, V-MAX, V-DEST	Jerárquica	Manhattan	2	single/mcquitty/median/centroid	0.75	2.01	0.18	0.71
C1NS	1xPARADA, V-PROM	Jerárquica	Manhattan	2	centroid	0.43	3.24	0.29	0.57
C1NS	1xPARADA, V-MAX	Jerárquico	Manhattan	2	ward.D	0.36	28.26	0.35	1.21
C1NS	1xPARADA, V-PROM, V-MAX, V-DEST	Jerárquica	Manhattan	2	average	0.53	16.39	0.27	1.60
C1NS	3xPARADA, V-PROM	Jerárquica	Máxima	2	average	0.49	2.56	0.18	1.80
C1NS	3xPARADA, V-MAX	Jerárquica	Manhattan	2	single/average/mcquitty/median/centroid	0.56	2.70	0.26	0.62
C1NS	3xPARADA, V-PROM, V-MAX, V-DEST	Jerárquica	Manhattan	2	single/average	0.70	2.12	0.20	0.69
C1SN	1xPARADA, V-PROM	Jerárquica	Manhattan	2	median/centroid	0.48	3.05	0.28	0.59
C1SN	1xPARADA, V-MAX	Jerárquica	Manhattan	2	average	0.30	6.90	0.30	0.74
C1SN	1xPARADA, V-PROM, V-MAX, V-DEST	Jerárquica	Máximo	2	single/average/mcquitty/median/centroid	0.63	2.84	0.26	0.73
C1SN	3xPARADA, V-PROM	Jerárquica	Máximo	2	single/average/mcquitty/median/centroid	0.51	3.40	0.31	0.76
C1SN	3xPARADA, V-MAX	Jerárquica	Euclideana	2	single/average/mcquitty/median/centroid	0.63	1.86	0.16	0.71
C1SN	3xPARADA, V-PROM, V-MAX, V-DEST	Jeráquica	Máxima	2	single/complete/average/centroid	0.54	2.55	0.23	0.94

Ruta E1: 1xPARADA, V-MAX
Método: Clustering jerárquico (single/centroid , Máxima, k= 2)
Índices: Silueta = 0.41, Davies-Bouldin = 0.73, Dunn = 0.56, Calinski = 4.89
A primera vista, esta configuración parece representar un clustering razonable: el coeficiente de Silueta $s = 0{,}41$ se aproxima al umbral de clustering satisfactorio ($s > 0{,}40$), el índice Davies-Bouldin $DB = 0{,}73$ (excelente)

y el índice Dunn $D = 0{,}56$ (favorable) sugieren clusters compactos y bien separados.
Sin embargo, al analizar la composición de los clusters, se observa un **desbalance extremo**: $n_1 = 112$ viajes se agrupan en un cluster mientras que solo $n_2 = 1$ viaje forma el segundo cluster. Esta distribución tan desigual indica que el segundo cluster corresponde a un **punto atípico (*outlier*)** en lugar de representar un patrón de conducción genuino. Los índices de validación resultan artificialmente favorables debido a la separación obvia entre el grupo principal y este dato aislado.
Al eliminar este punto atípico y repetir el análisis, persiste el problema: nuevamente se forma un cluster con 112 viajes y otro con solo 1. Además, al evaluar diferentes métodos de clustering jerárquico (single, complete, average, ward) y métricas de distancia (euclidiana, Manhattan, máxima), el **índice de Silueta cae consistentemente** ($s < 0{,}30$), lo cual indica **estructura débil o ausente** de clusters naturales.En conclusión, los datos de velocidades máximas **no presentan agrupaciones naturales claras**.

Ruta C1NS: 1xPARADA, V-PROM, V-MAX, V-DEST
Método: Clustering jerárquico (average, Manhattan, k= 2)
Índices: Silueta = $0{,}27$, Davies-Bouldin = $1{,}60$, Dunn = $0{,}53$, Calinski = $16{,}39$
Esta configuración representa un clustering **muy débil y poco confiable**. Con Silueta de $0{,}27$, apenas alcanza el umbral mínimo de estructura detectable ($> 0{,}25$), indicando solapamiento considerable entre grupos. El Davies-Bouldin desfavorable ($1{,}60$) y el Dunn moderado-bajo ($0{,}53 < 1{,}0$) confirman clusters con separación limitada y compacidad insuficiente. Los resultados tienen **confiabilidad muy baja y no son adecuados para uso operativo**. Las variables de velocidad no capturan patrones de conducción claramente diferenciados en esta ruta.

Ruta C1SN: 3xPARADA, V-PROM
Método: Clustering jerárquico (single/average/mcquitty/median/centroid, Máxima, k= 2)
Índices: Silueta = 0.31, Davies-Bouldin = 0.76, Dunn = 0.51, Calinski = 2.56
Esta configuración con mayor granularidad representa un clustering **en**

el límite bajo-razonable con confiabilidad limitada. Con Silueta de 0.31, muestra estructura definida pero con solapamiento moderado entre clusters. El Davies-Bouldin favorable (0.76) y Dunn moderado (0.51) confirman cierta separación geométrica. Los resultados tienen **confiabilidad moderada-baja**.

Referencias bibliográficas

[1] Jesús Abel García García. Algoritmos de clustering: número de clusters. https://digibuo.uniovi.es/dspace/bitstream/handle/10651/64381/TFG_JesusAbelGarciaGarcia1.pdf?sequence=4&isAllowed=y, July 22 2022. Trabajo Fin de Grado, 77 páginas. Accedido el 29 de octubre de 2025.

[2] Editorial Icesi. Una introducción a los modelos de clústering empleando r: 2 generalidades y métricas en el clústering. https://www.icesi.edu.co/editorial/intro-clustering-web/Metricas.html#Ãndice-db, n.d. Accedido el 29 de octubre de 2025.